

Contents

4	Regressió simple: Intervals pels paràmetres. Bandes de confiança i de predicció.	2
4.1	Intervals de confiança per als parametres	2
4.2	Bandes de confiança i de predicció de noves observacions	3

Pràctica 4

Regressió simple: Intervalls pels paràmetres. Bandes de confiança i de predicció.

- Intervalls per als coeficients. • Interval per a la variància.
- Banda de confiança per a la resposta mitjana. • Banda de predicció. • Gràfiques de les bandes.

Utilitzarem les funcions de R: `lm()`, `summary(lm())`, `confint()`, `predict()`, `matplot()`, i noves funcions creades per l'usuari: `CI.var()`, `bandes()` i `wh.bandes()`

4.1 Intervalls de confiança per als parametres

Torna a carregar les dades de y =preu i x =consum.

```
require(foreign)
data<-read.spss("preuconsum.sav",to.data.frame=T)
data<-data[!is.na(data$ID),1:3] ## eliminem els NA, casos que tots els valors son NA
names(data)<-c("id","y","x")
attach(data)# opcional
```

Guarda el resultat del model lineal de y sobre x en l'objecte `mod` i el sumari en l'objecte `smod`. Recorda: l'opció `x=TRUE`, `y=TRUE` dins de `lm()` fa que les dades x i y apareguin a l'output de la funció.

```
mod<-lm(y~x,data=data,x=TRUE,y=TRUE) ## no cal attach si posem el nom del fitxer dins de lm()
smod<-summary(mod)
names(mod)
mod$x; mod$y ## per recuperar les dades inicials de l'output del model
```

1. A partir de `mod` i `smod`, guarda cadascun dels valors següents de manera individual en un objecte que es pugui fer servir després (noms suggerits entre parèntesis).

- l'estimació de la intersecció (o intercept) $\hat{\beta}_0$: com interpreteu el valor? (`beta0`)
- l'estimació del pendent $\hat{\beta}_1$: com interpreteu el valor? (`beta1`)
- l'estimació de l'error típic de $\hat{\beta}_0$ i de $\hat{\beta}_1$ (`s.beta0` i `s.beta1`)
- els graus de llibertat de la distribució t — de Student (`gl`)
- el valor de l'estadístic de contrast de $H_0 : \beta_0 = 0$ (`t.beta0`)
- el valor de l'estadístic de contrast de $H_0 : \beta_1 = 0$ (`t.beta1`)
- el p-valor del contrast $H_0 : \beta_0 = 0$ bilateral: com interpreteu el resultat? (`p.beta0`)

- el p-valor del contrast $H_0 : \beta_1 = 0$ bilateral: com interpreteu el resultat? (`p.beta1`)
 - l'estimació de la variància del model $\hat{\sigma}^2$ (MSE)
 - l'estimació de R-quadrat $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$, on $SSE = \sum e_i^2$ i $SST = \sum (y_i - \bar{y})^2$ (R2). Com interpretes el resultat obtingut?
 - l'estimació de R-quadrat ajustat: $R_a^2 = 1 - \frac{MSE}{MST} = 1 - \frac{\frac{SSE}{n-2}}{\frac{SST}{n-1}}$. (R2.a) *Observació:* El coeficient de determinació ajustat permet comparar diversos models de regressió.
2. Amb els errors típics i els graus de llibertat guardats al problema anterior, calcula les quantiles de la distribució que pertoca i, seguidament, l'interval de confiança (lsup i linf), amb un NC del 95%, per a cada coeficient, β_0 i β_1 .

```
## $linf.beta0
## [1] 4.315113
##
## $lsup.beta0
## [1] 4.601048
##
## $linf.beta1
## [1] -1.335924
##
## $lsup.beta1
## [1] -1.201588
```

3. Utilitza la funció `confint()`, aplicada al model, per obtenir els intervals de confiança per als coeficients i comprova que són (aproximadament) els mateixos que has calculat a l'apartat anterior. Interpreta els intervals.

Canvia el nivell de confiança al 99%, calcula de nou els intervals i comenta els canvis.

4. Fes el codi d'una funció que anomenaràs `CI.var(x,y, nc=0.95)` (recorda que el valor numèric que s'assigna a un argument a la definició d'una funció és només el valor per defecte, el qual es pot canviar quan s'aplica la funció), aquesta funció ha de retornar l'estimació puntual de σ^2 i l'interval de confiança per al nivell de confiança desitjat. *Indicació:* dins de la funció li faràs calcular `mod` i `smod` per extraure informació d'aquests objectes. Recorda: **no fer servir dins d'una funció objectes que hi ha fora de l'espai. Tots els objectes han de provenir dels arguments de la funció.** Aplica la funció per calcular l'interval amb un nivell de confiança del 99%.

```
CI.var<-function(x,y,nc=0.95){
.
.
.
}
```

```
## $MSE
## [1] 0.003359123
##
## $linf.sigma2
## [1] 0.002459166
##
## $lsup.sigma2
## [1] 0.004865029
```

4.2 Bandes de confiança i de predicció de noves observacions

1. Considerem un vector de dades noves que posarem en forma de dataframe (`newdata`) -li direm `xh`, per abreviar-.

Observació important: Dins del data frame de dades noves, la variable independent ha de tenir el mateix nom que a la base de dades d'on s'ha extret el model. Tingues en compte que la funció `predict()` dona les prediccions de `newdata`.

```
xh<-data.frame(x=seq(1.85,2.51,by=.03)) ## ATENCIÓ !!
## a la variable del data.frame li posem el MATEIX NOM que a les dades!! ("x", pel cas del preu consum)
## si volguéssim predir uns pocs valors, fariem: xh<- data.frame(x=c(1.7,2.1))
predict(mod,newdata=xh)
```

Fes una funció (`bandes(x,y,xh,level)`) que calculi la **banda de confiança per a la resposta mitjana** i la **banda de predicció** d'aquestes observacions. Per assajar, pots considerar que el vector de dades noves és el vector `xh` que apareix al chunk. *Nota:* Dins del codi de la funció `bandes()`, pots utilitzar la funció `predict(mod,newdata)` per obtenir les prediccions de “noves observacions”.

```
bandes<-function(x,y,xh,level=.95){
.
.
.
}
```

L'output de la funció aplicada a les dades de preu i consum i a `xh` anterior amb nivell de confiança del 95%, ha de ser el data.frame del qual es mostra la capçalera:

```
head(bandes(data$x,data$y,xh))

##      new      pred      lmean      umean      lpred      upred
## 1 1.85 2.110883 2.088103 2.133662 1.992977 2.228788
## 2 1.88 2.072820 2.051599 2.094040 1.955205 2.190435
## 3 1.91 2.034757 2.015013 2.054502 1.917400 2.152115
## 4 1.94 1.996695 1.978323 2.015066 1.879560 2.113829
## 5 1.97 1.958632 1.941506 1.975757 1.841687 2.075577
## 6 2.00 1.920569 1.904532 1.936606 1.803778 2.037360
```

2. Plot de les bandes. Utilitzem la funció `matplot()` per fer diverses corbes alhora.

```
xbandes<-xh
ybandes<-bandes(data$x,data$y,xh)[-1] ## omitim la 1a columna "new" de l'output de bandes !!

matplot(xbandes, ybandes, ylim=c(min(ybandes),max(ybandes)),
        lty = c(1,1,1,2,2), col=c(1,2,2,4,4), type = "l",
        ylab = "prediccions del consum",xlab="preu",
        main="bandes de confiança (vermell) i de predicció (blau)", cex.main=.8)
points(data$x,data$y,pch=20,cex=.8)
```

3. Comprova que *no caldria haver creat al funció `bandes()`* perquè el codi següent dona les bandes utilitzant la funció `predict()` de R:

```
conf.band<-predict(mod,newdata=xh,interval="confidence")
## la primera columna són les estimacions de la resposta mitjana
pred.band<-predict(mod,newdata=xh,interval="prediction")
## la primera columna, prediccions puntuals, és repetida de l'anterior
ybandes2<-data.frame(conf.band,pred.band[-1]) ## traïem 1a columna repetida
```

Fés el `matplot` per veure que és el mateix resultat.

4. Comprova que també s'obté el mateix amb la funció `plotFit()` de la llibreria `investr`:

```
require(investr)
plotFit(mod,"both")
plotFit(mod,"both",pch=19,cex=.8,shade=T,col.conf = "skyblue4", col.pred = "lightskyblue2")
```

5. Bandes de confiança i de predicció de *Working-Hotelling* **amb correcció per múltiples intervals o bandes de confiança experimentals**. Cal fer la funció `wh.bandes(x,y,level=.95)` i la grafica. *Nota:* les fórmules són idèntiques al codi anterior, només canvia la quantila *t*-Student per *w*:

$$w = \sqrt{2 * F_{1-\alpha,2,n-2}}$$

Observació: Les bandes de Working-Hotelling són molt més segures (més àmplies) per a totes les prediccions simultànies, però són més ajustades que les de Bonferroni. A més. les de Bonferroni són cada cop més grans, quantes més prediccions fem, i les de W-Hotelling no,2 perquè només depenen del nombre de dades *n* amb les quals s'ha estimat el model.

```
wh.bandes<-function(x,y,xh,level=.95){
  .
  .
  .
}
head(wh.bandes(data$x,data$y,xh))
```

Mostra la capçalera del data.frame resultant.

```
head(wh.bandes(data$x,data$y,xh),3)

##      new      pred wh.lmean wh.umean wh.lpred wh.upred
## 1 1.85 2.110883 2.088103 2.133662 1.962998 2.258767
## 2 1.88 2.072820 2.051599 2.094040 1.925301 2.220339
## 3 1.91 2.034757 2.015013 2.054502 1.887561 2.181953
```

Fes un matplot de les bandes de Working-Hotelling.

Comprova que s'obté el mateix resultat fent ...

```
require(investr)
plotFit(mod,"both",adjust="Scheffe",k=2)
```